Pr Samba NDIAYE
UCAD/FST
Département de Mathématique-Informatique

Janvier 2025

Canevas pour la rédaction du mémoire de master en Data science/Machine learning

***Remarque** : ce travail est une tentative. Toutes les remarques sont les bienvenues.*

Profil : Data science / Machine Learning

Remarque : il y a un exemple traité à la fin du document

I. Plan du mémoire :

Un mémoire doit posséder un plan à suivre.

Ci-dessous un exemple de plan pour les mémoires consacrés au développement logiciel.

Des variantes pour les mémoires en Informatique décisionnelle ou Business Intelligence (BI), en Data Science ou Machine Learning seront proposées.

PLAN

1. **Chapitre n°1 : Introduction Générale**
    1. **Contexte**
    2. **Problématique**
    3. **Objectifs du mémoire**
    4. **Intérêts du sujet**
2. **Chapitre n°2 : Solutions ou Outils similaires/Travaux existants**

L'objectif est de voir s'il y a des outils similaires dans le monde. Si oui, nous allons nous en inspirer et se comparer à eux plus tard (pour faire au moins aussi bien).

1. **Critères de comparaison fonctionnels**
2. **Critères de comparaison non-fonctionnels**
3. **Étude détaillée de chaque solution similaire (par rapport aux critères fonctionnels et non-fonctionnels)**
4. **Tableau comparatif n°1 pour les critères fonctionnels**
5. **Tableau comparatif n°2 pour les critères non-fonctionnels**
6. **Conclusion majeure tirée des deux tableaux comparatifs**

3. **<u>Chapitre n°3 : Analyse de l'existant et Conception de la solution proposée</u>**
    1. **Cas d'utilisation métier existants (enlevez les fonctionnalités système cad connexion/déconnexion, etc.)**
    2. **Cas d'utilisation métier de la future solution (enlevez les fonctionnalités système cad connexion/déconnexion, etc.)**
    3. **Les autres Diagrammes UML (diagrammes des activités, diagrammes de classe)**
    4. **Les Dessins des IHM métier**
    5. **Architecture fonctionnelle de la future solution**
    6. **Outils utilisés**
4. **<u>Chapitre n°4 : Réalisation de la solution proposée</u>**
    1. **R**
    2. **R**
    3. **D**
    4. **Architecture technique de la future solution**
    5. **Outils utilisés**
5. **<u>Chapitre n°5 : Conclusions et perspectives</u>**
    1. **Conclusions (par rapport au point « Objectifs du mémoire » du chapitre n°1.**
    2. **Perspectives (les objectifs du mémoire non atteints, les objectifs de la problématique non choisis, autres)**

II. Plan détaillé = CANEVAS DE REDACTION DU MÉMOIRE DE MASTER

1. Sujet du mémoire :

il doit respecter les trois points suivants :

1. **il doit être bien formulé et facilement compréhensible par le public général (vos amis et proches par exemple, les personnes présentes lors de la soutenance, etc.) ;**
2. **il doit désigner l'objectif général du mémoire ;**
3. **il doit comporter les expressions similaires aux termes « *Conception* » et « *Réalisation* », puisque c'est un travail d'ingénieur de conception, de niveau BAC+5.**

2. **Chapitre n°1 : Introduction générale** *(10 à 12 pages)*

    1. **Le contexte du sujet décrit des difficultés clairement identifées dans un processus de gestion au sein d'une organisation (ou dans la société) que l'on cherche à résoudre.** Rappelons *qu'un processus est un ensemble d'activités corrélées ou en interaction qui utilise des éléments d'entrée pour produire un résultat escompté, selon la norme ISO 9000 :2015 (Wikipédia).*
        - **Le contexte est donc un problème pratique identifié au sein d'une organisation ou dans la société.**
        - **D'abord, il faut présenter l'organisation/la direction/le département au sein de laquelle se déroule le stage, il faut décrire ce processus, identifier les activités/tâches et enfin identifier les acteurs qui réalisent ces activités/tâches. Un schéma BPMN serait un plus.**
        - **Ensuite, il faut identifier de façon précise et détaillée les difficultés rencontrées par les acteurs lors l'exécution des activités/tâches.**

- **Acteur n°1 :**
    - **Difficulté n°1 : à détailler**
    - **Difficulté n°2 : à détailler**
    - **Difficulté n°3 : à détailler**
    - **….**
- **Acteur n°2 :**
    - **Difficulté n°1 : à détailler**

        - **Difficulté n°2 : à détailler**
        - **Difficulté n°3 : à détailler**
        - **….**
    - **Etc.**
        - **En résumé, le contexte est une partie essentielle du mémoire. Il doit sérieusement être réalisé et détaillé. On y met en relief toutes les difficultés rencontrées par l'organisation dans la réalisation d'un processus de gestion. C'est un problème de gestion de l'organisation.**
        - **Le contexte est, en fait, un prétexte pour introduire la problématique de l'étudiant. La problématique sera la solution proposée par l'étudiant pour résoudre toutes les difficultés identifiées dans le contexte.**

Au final, il faut donc bien écrire le contexte, de façon détaillée, documentée, précise et rigoureuse. Ce travail d'écriture du contexte est décisif car celui-ci impacte les parties suivantes comme :

- **la Problématique au sein du chapitre 1,**
- **l'Analyse de l'existant au sein du chapitre 2,**
- **les cas d'utilisation existants au sein du chapitre 3.**

Pour écrire le contexte, on s'aide en se posant les questions de recherche suivantes :

<u>Question 1</u> : Quel est le processus de travail (gestion) étudié ?

<u>Question 2</u> : Quelles sont les activités de ce processus ? Faire une description détaillée et documentée des activités successives de ce processus. ¨Pour chaque

activité, qui est ou qui sont les acteurs ? Au final, lister les activités rangées par acteur. Lister aussi les acteurs par ailleurs.

Question 3 : Quelles sont les difficultés (problèmes) rencontrées par les acteurs dans l'exécution de chaque activité/tâche ? Ici aussi, faire une description détaillée et documentée des problèmes rencontrés par les acteurs.

Remarque : si possible, faire un schéma BPMN de ce processus d'activités.

2. Problématique

(c'est le travail à faire par l'étudiant avec des objectifs (général et spécifiques) à atteindre)

La problématique de l'étudiant est de concevoir et de d'implémenter une solution informatique basée sur un outil Data science (algorithme/modèle de machine learning) qui viendra résoudre les difficultés de gestion identifiées dans le contexte. L'étudiant devra montrer comment les fonctions ou fonctionnalités de son outil Data science vont résoudre une à une toutes les difficultés des acteurs qui ont été listées dans le contexte.

La problématique est donc un ensemble de travaux informatiques pour l'étudiant dans les domaines de la recherche documentaire, de l'analyse de l'existant, de conception et de réalisation d'applications, pour obtenir une solution informatique basée sur un outil de data science dont les fonctionnalités permettront de résoudre les difficultés des acteurs identifiées dans le contexte.

Au final, dans la problématique, l'étudiant doit :

- **Identifier l'objectif général de ses travaux, c'est-à-dire concevoir et réaliser une solution informatique basée sur un outil de data science pour résoudre des problèmes/difficultés identifiés dans le contexte. (En fait, c'est le titre du mémoire) ;**
- **Lister les les objectifs spécifiques de ses travaux qui sont fonctionnalités principales ou métier de sa solution/outil ;**
- **Montrer comment ces fonctionnalités principales/métier permettront de résoudre toutes les difficultés listées dans le contexte. Ainsi, l'étudiant établit clairement des liens entre les fonctionnalités de son outil informatique basée sur la data science/machine learning et les difficultés identifiées dans le processus de gestion.**

La Problématique va proposer :

- **Un objectif général qui sera une solution informatique basée sur un outil de data science (application, plateforme, etc.)**
- **Des objectifs spécifiques qui seront les fonctionnalités (ou objectifs spécifiques) de cette**

solution informatique. Celles-ci seront listées par acteur.

- **Acteur n°1 :**
  - **Fonctionnalité n°1 : à détailler**
  - **Fonctionnalité n°2 : à détailler**
  - **Fonctionnalité n°3 : à détailler**
  - **….**
  - **Fonctionnalité n°p : à détailler**
- **Acteur n°2 :**
  - **Fonctionnalité n°1 : à détailler**
  - **Fonctionnalité n°2 : à détailler**
  - **Fonctionnalité n°3 : à détailler**
  - **….**
  - **Fonctionnalité n°p : à détailler**
- **Etc.**

Remarque n°1 : la solution informatique pourrait avoir plusieurs dizaines de fonctionnalités ou services ou fonctions.

Remarque n°2 : Ces fonctionnalités joueront un rôle décisif dans les chapitres suivants. En effet, elles serviront de critères de recherche dans le chapitre 2 intitulé « Solutions similaires ». Dans le chapitre 3 intitulé « Analyse de l'existant et conception de la nouvelle solution », elles permettront de réaliser rapidement les diagrammes des cas d'utilisation par acteur.

3. Objectifs du mémoire :

On annonce ici la liste des fonctionnalités ou objectifs spécifiques que l'étudiant pourra réaliser dans les six mois que vont durer le stage ou le mémoire.

C'est donc une sous-partie des fonctionnalités ou objectifs spécifiques.

Exemple : on annonce les objectifs qui seront effectivement réalisés

- **Objectif n°1 :XXXXXXXXXXXXXXXXX**
- **Objectif n°2 :XXXXXXXXXXXXXXXXX**
- **Objectif n°3 :XXXXXXXXXXXXXXXXX**
- **Objectif n°4 :XXXXXXXXXXXXXXXXX**
- **…….**
- **……**
- **Objectif n°K :XXXXXXXXXXXXXXXXX**

Ainsi, dans le chapitre n°5 appelé « Conclusions et Perspectives » du mémoire, l'étudiant dira s'il a atteint ou non ses objectifs c'est-à-dire les objectifs du mémoire.

4. Intérêts du sujet :

- **Intérêts pour l'organisation : lister les avantages de votre solution pour l'organisation ou la société.**
- **Intérêts pour l'étudiant : lister les avantages de votre solution pour vous (compétences acquises, expériences, technologies apprises et maitrisées, profil pour recrutement, avancement, etc.)**

3. Chapitre n°2 : Solutions similaires dans le monde entier *(au moins dix solutions similaires, 12 à 20 pages)*

1. **Rappels sur notre problématique. Il s'agit de concevoir et réaliser une solution informatique ayant les fonctionnalités F1, F2, F3, F4, F5, ……, F20, etc.**
2. **Nous allons faire des recherches de documents concernant des solutions similaires, récentes, déjà conçues et réalisées dans le monde. Nos recherches se feront dans les bibliothèques des universités et des établissements d'enseignement supérieur, et dans le Web. Voir tutoriels sur la recherche documentaire.**
3. **Pour chaque solution similaire, nous identifions les fonctionnalités présentes (il s'agit essentiellement des fonctionnalités métier).**
4. **Nous prenons en compte aussi certains aspects non fonctionnels, par exemple si la solution similaire est-elle open-source, sécurisée, cloud, interface Web, interface mobile ? Quelle est son architecture ? Quel est son système d'exploitation, etc.**
5. **On rassemble toutes les études dans deux tableaux comparatifs toutes ces solutions trouvées dans le monde. Nous créons un premier tableau comparatif avec les critères fonctionnels et un second tableau comparatif des critères non-fonctionnels.**

Tableau de comparaison des critères fonctionnels					
	F1	F2	F3	…….	F20
Solution1	oui	non			
Solution2					
Solution3					
……					
Solution10					

Tableau de comparaison des critères non-fonctionnels						
	Interface Web /mobile	Architecture	SE	Open Source	Cloud	Sécurité
Solution1						
Solution2						
Solution3						
……						
Solution10						

6. **On termine ce chapitre par une conclusion majeure. Existe-t-il dans le monde une solution informatique basée sur un outil de data science qui remplit toutes les conditions et que nous pouvons utiliser comme solution pour notre problématique ? Ou bien, sommes-nous obligés de concevoir et de réaliser une nouvelle solution parce que les solutions similaires ne sont pas satisfaisantes pour des raisons que nous devons préciser avec soin ? Les réponses à ces questions vont déterminer la suite de vos travaux de mémoire.**

4. Chapitre n°3 : Analyse de l'Existant (au sein de l'organisation) et Conception de la solution proposée *(20 à 35 pages)*

1. **Analyse de l'Existant ou analyse de la situation existante au sein de l'organisation (cet existant souvent manuel, ou déjà informatisé mais à mettre à jour). Réalisez :**
    a. **Les diagrammes des cas d'utilisation existants de chaque acteur s'ils existent. Ces diagrammes de cas d'utilisation représentent la situation décrite dans le contexte pour chaque acteur.**
    b. **Les aspects non-fonctionnels de la situation actuelle (interface web, architecture, open source, SE, langages utilisés, sécurité, cloud, etc.) sont bien identifiés.**

    Remarque : Ce travail est très important. Il montre la situation actuelle. Celle-ci pourra être comparée à la future situation quand notre solution sera déployée. Vous pourrez ainsi prouver les progrès réalisés grâce à votre solution.

2. **Conception de la solution proposée**
    a. **Réalisez les diagrammes des cas d'utilisation futurs càd les nouvelles fonctionnalités/services que votre solution va apporter. C'est la situation déjà décrite dans la problématique.**
        i. **Lister tous les acteurs déjà Identifiés dans la problématique**
        ii. **Pour chaque acteur, lister les fonctionnalités/ fonctions/ tâches /services/activité) que votre solution lui permettra de réaliser ;**
        iii. **Pour chaque tâche, identifier l'entité ou objet de donnée manipulée ;**
        iv. **Dessiner le diagramme des cas d'utilisation par chaque acteur**

    b. Parmi les services rendus par votre application, le principal service est un outil de prédiction/prévision (classification/régression). Ou bien un outil de clustering/segmentation. C'est donc un outil de data science qui va s'appuyer sur un algorithme/modèle de

machine learning pour faire de la prédiction/prévision ou de la segmentation (regroupement).

i. **L'outil que vous concevez permettra alors de prédire l'état d'une des entités ? Laquelle ?**
ii. **Ou bien, cet outil fera des segmentations**
iii. **Quelle est cette entité ? Quelles sont ses caractéristiques (attributs) ?**
iv. **Quelle est la variable à prédire ou variable cible au sein de cette entité ? Quel est son format ?**
v. **Quels sont les variables prédictives, qui permettront de déterminer la variable cible ? Quels sont leurs formats (numérique, Textuel, images, son, vidéo ?**
vi. **Ces variables prédictives proviennent de quelles entités ?**
vii. **Comment obtient-on le tableau constitué par les variables prédictives et la variable cible ?**
viii. **Dans le chapitre 4, nous allons principalement nous focaliser sur la réalisation de cet outil de data science. Il faudra identifier les sources de données, construire le tableau, choisir le meilleur modèle de machine learning qui donnera les meilleurs résultats pour le travail de prédiction/prévision.**

5. Chapitre n°4 : Réalisation de la solution proposée *(20 à 35 pages)*

Il ne reste qu'à réaliser le travail en suivant les étapes suivantes.

(tiré du cours Machine de ZEMMARI, Université Bordeaux,

https://www.labri.fr/perso/zemmari/ia_data/pdfs/07__ml-introduction.pdf)

Étapes à suivre pour concevoir un système ML

Etape 1. Formaliser la tâche d'apprentissage

- Définir la tâche que l'on veut traiter avec le système d'apprentissage (exemple : reconnaître des caractères à partir d'images).
- Un problème d'apprentissage est souvent composé de plusieurs tâches :
  - Découper l'image en mots et chaque mot en caractères.
  - Identifier la langue.
  - Classer chaque caractère dans l'alphabet de la langue.
- Choisir une mesure de performance pour évaluer le système d'apprentissage (exemple : nombre de caractères mal classés).

Étape 2. Collecter les données

- Un ensemble d'entraînement doit être collecté dans un format lisible par la machine.
- La collecte de données est une tâche souvent très lourde. Elle implique une intervention manuelle, en particulier pour l'étiquetage des exemples pour l'apprentissage supervisé.

Étape 3. Extraire les features

- On doit extraire un ensemble de features des données, ce seront les entrées au système d'apprentissage.
- Il est nécessaire d'avoir des connaissances "métier" pour savoir choisir les features appropriés à la tâche d'apprentissage considérée.
- Si on choisit trop peu de features, on peut passer à côté d'informations importantes pour la classification.
- Si on en sélectionne trop, il faut disposer de beaucoup de données pour l'entrainement.

Étape 4. Choisir la bonne catégorie de modèles d'apprentissage

- Un modèle simple comme un classifieur linéaire peut être facile à entraîner mais peut s'avérer inefficace pour des données non linéairement séparables.
- Un modèle trop complexe peut mener à du sur-apprentissage (overfitting) et peut ne pas se généraliser pour de nouveaux exemples.
- Exemple : régression linéaire vs régression polynomiale ...

Étape 5. Entrainer le modèle

- Chercher dans l'espace des modèles possible (en fonction de la classe du modèle recherché).
- $\rightarrow$ Adapter le modèle aux exemples disponibles en s'assurant que la performance du modèle est bonne.
- La modèle entrainé doit être performant sur des données qu'il n'a jamais vues (généralisation). S'assurer que le modèle n'apprend pas par coeur les exemples qui lui ont été présentés (overfitting).

Étape 6. Evaluer le modèle

- Le modèle est évalué sur sa capacité à généraliser à des exemples qu'il n'a jamais vus.
- L'evaluation peut donner des indications sur les faiblesses du modèle et peut suggérer des modifications et des raffinements possibles ...
- Mais attention au piège dans lequel tombent la plupart des concepteurs de solutions ML : ne pas séparer le test de la validation (cela mérite quelques explications ...)

6. Chapitre n°5 : Conclusions et perspectives. *(2 à 5 pages)*

1. Conclusions
    a. Oui, j'ai atteint l'objectif n°1 du mémoire qui était de …….

        J'ai pu concevoir et réaliser…….

    b. Oui, j'ai atteint l'objectif n°2 du mémoire qui était de …….

        J'ai pu concevoir et réaliser…….

    c. Oui, j'ai atteint l'objectif n°3 du mémoire qui était de …….

        J'ai pu concevoir et réaliser…….

    d. Non, je n'ai pas atteint l'objectif n°4 du mémoire qui était de …….

        Parce que ……

    e. Etc.
    f. Etc.
2. Perspectives
    a. Rappeler les objectifs du mémoire non atteints
        i. Perspective n°1
        ii. Perspective n°2
        iii. ……
    b. Rappeler les objectifs spécifiques non choisis dans les objectifs du mémoire
        i. Perspective n°
        ii. Perspective n°
    c. Autres perspectives
        i. Perspective n°
        ii. Perspective n°

<u>Exemple traité</u> : **« Conception et Réalisation d'une application de Détection Automatique des faux billets de banque** »

a. Écrire le contexte : Zone UEMOA, Banque Centrale BCEAO, Franc CFA, détection de la circulation de faux-billets en quantité non-négligeable, régulièrement, la presse fait état de saisies de fausse monnaie. C'est devenu un fléau à éradiquer au plus vite. La BCEAO et les banques prennent des mesures. Des machines de détection sont installées dans les établissements financiers. Mais qu'en est-il des petits commerçants, boutiquiers, etc. qui n'ont les moyens d'installer ces machines et de contrôler chaque billet reçu ?
   Quel est processus d'activités étudié ? Il s'agit de la détection des faux billets de banque au Sénégal.
   Quelles sont les activités du processus ? Recevoir un billet de banque, vérifier une centaine de caractéristiques avec une machine de détection, si le faux est faux, alors informer la Police et la Justice et la BCEAO.
   Quels sont les acteurs de ce processus ? Établissement financier, PME-PMI, commerçant (recevoir, vérifier, informer Police et Justice)
   Quels sont les acteurs ? Établissements financiers, Entreprise, petit commerçant, (acteurs internes) ; Police, Justice (acteurs externes). La Police, la Justice, la BCEAO veulent des informations sur les faux billets, les faux-monnayeurs et les organisations criminelles derrière ce trafic.
   Quelles sont les difficultés rencontrées par les acteurs dans l'exécution des tâches ?
   Ce sont surtout les PME-PMI et les petits commerçants qui connaissent de réelles difficultés. Ils n'ont pas les moyens d'acheter des machines de détection. Ils n'arrivent à détecter les faux billets et subissent alors de grosses pertes. La BCEAO
b. Écrire la problématique : Comment mettre fin aux pertes subles par les PMI et les commerçants ? Concevoir et réaliser une application utilisant l'IA et installée sur les téléphones portables et qui permettra aux commerçants de vérifier chaque billet reçu.
   Cette app permettra aux commerçants d'éliminer leurs pertes.
   Elle permettra à la BCEAO d'éliminer ce fléau,
   Elle donnera à la Police et à la Justice les informations nécessaires pour traquer les faux-monnayeurs.
c. Écrire les solutions similaires
d. Écrire la solution proposée
   i. Existant : machines de détection. Description, marques, coûts, mode de fonctionnement, efficacité, nombre de billets examinés par minute ou heure
   ii. Mon application.
      Cas d'utilisateur Acteur = petit commerçant,
      activités = photographier billet, identifier billet, vérifier validité du billet, accepter billet, rejeter billet, envoyer message aux autorités (BCEAO, Police, Justice)
      L'activité « vérifier billet » va reposer un algorithme IA de détection (Vision, Photographie).
      L'entité manipulée est l'entité « billet ». Cet entité « billet » aura un état « Vrai » ou « Faux »

iii. Quelles sont les variables descriptives qui permettront de déterminer la classe d'un billet ? Conception du modèle de données