REPUBLIQUE DU SENEGAL



Un peuple-un but-une foi

Ministère de l'Enseignement Supérieur, de la Recherche et de l'Innovation

Direction de l'Enseignement Supérieur Privé

Institut Supérieur d'Informatique

ISI

Mémoire de fin de cycle pour l'obtention du master professionnel en Informatique Appliquée à la Gestion des Entreprises

Option : Big Data Management & Analytics

Mise en place d'un pipeline de données pour l'indigestion et l'analyse des logs système dans un environnement Big Data

Présenté et soutenu par :

Mlle. IBRAHIM M. Assaira

Mlle. CISSE Aicha

Mlle. KOYAKOSSO Rodelva

M. BARRY Amadou Tidiane

M. DRAME Samba

Sous la direction de :

Mme. CISSE Fatou

Spécialité :

Année Académique : 2024 -2025

Avant-propos

L'institut Supérieur d'Informatique (ISI), créé en 1988, est un établissement d'enseignement supérieur privé qui dispense des formations en informatique et en gestion. Il propose de multiples spécialités telles que : l'informatique appliquée à la gestion des entreprises (options Développement et Management des ERP et Big Data Management & Analytics), la comptabilité, l'infographie, les réseaux informatiques, les réseaux télécommunications, le génie logiciel. Il délivre les diplômes suivants : Brevet de Technicien Supérieur (BTS), Diplôme de Technicien Supérieur (DTS), Licence et Master Professionnels qui pour la plupart sont reconnus par le CAMES et ANAQSUP.

Pour l'obtention du master professionnel en informatique appliquée à la gestion des entreprises option Big Data Management & Analytics, l'Institut Supérieur d'Informatique (ISI) exige aux étudiants la rédaction d'un mémoire de fin de cycle. C'est dans ce cadre que nous avons élaboré ce document qui a pour sujet : **Mise en place d'un pipeline de données pour l'ingestion et l'analyse des logs système dans un environnement Big Data.**

Ce sujet a donc pour objet l'analyse de flux qui consiste à collecter, traiter et analyser les tweets au fur et à mesure qu'ils sont publiés. Ce type d'analyse permet d'obtenir des informations précieuses sur les tendances, les opinions du public, les événements en cours, et bien plus encore.

Plan détaillé

Chapitre 1 : Introduction Generale

1.1. Contexte

1.2. Problématique

1.3. Objectifs du mémoire

1.3.1. Objectif général

1.3.2. Objectifs spécifiques

1.4. Intérêts du sujet

1.4.1. Pour l'organisation

1.4.2. Pour l'étudiant

Chapitre 2 : Solutions Similaires

2.1. Critères de comparaison fonctionnels

2.2. Critères de comparaison non-fonctionnels

2.3. Etude détaillée des solutions similaires

2.4. Tableaux comparatifs

2.4.1. Tableau comparatif pour les critères fonctionnels

2.4.2. Tableau comparatif pour les critères non-fonctionnels

2.5. Conclusion majeure tirée des deux tableaux comparatifs

Chapitre 3 : analyse de l'existant et conception de la solution proposée

3.1. Use case métiers existants

3.2. Use case métier de la future solution

3.3. Diagrammes UML

3.3.1. Diagrammes des activités

3.3.2. Diagrammes de classe

3.4. Les dessins des IHM métiers

3.5. Architecture fonctionnelle de la future solution

3.6. Outils utilisés

Chapitre 4 : réalisation de la solution proposée

4.1. Réalisation du Backend

4.2. Réalisation Frontend (Interfaces Web et mobiles)

4.3. Déploiement de l'application (Conteneurs Dockers, etc.)

4.4. Architecture technique de la future solution

4.5. Outils utilisés

Chapitre 5 : conclusions et perspectives

5.1. Conclusions

5.2. Perspectives

Chapitre 1 : Introduction générale

Ce premier chapitre pose les fondations de notre étude. Il contextualise l'importance croissante de la gestion et de l'analyse des logs système, en particulier dans le contexte des environnements Big Data. Nous aborderons ensuite la problématique centrale qui motive ce travail, avant de définir clairement les objectifs que nous nous proposons d'atteindre. Enfin, nous soulignerons les intérêts et les bénéfices potentiels de cette recherche, tant pour les organisations que pour l'étudiant.

1.1. Contexte

L'ère numérique actuelle est caractérisée par une production exponentielle de données, et les logs système ne font pas exception à cette règle. Ces enregistrements, générés par les systèmes d'information, les applications et les infrastructures, constituent une mine d'informations précieuses sur leur fonctionnement, leur performance et leur sécurité. En conclusion de cette section, il apparaît clairement que la maîtrise des logs système dans un environnement Big Data est devenue un enjeu crucial pour les organisations souhaitant optimiser leurs opérations, anticiper les problèmes et garantir la sécurité de leurs systèmes. Cette prise de conscience de l'importance des logs dans le Big Data nous amène naturellement à explorer la problématique spécifique à laquelle nous souhaitons apporter des éléments de réponse.

1.2. Problematique

La capacité à collecter, stocker, traiter et analyser efficacement les volumes massifs de logs système générés dans un environnement Big Data représente un défi technique et organisationnel significatif. Les outils et les méthodes traditionnels peinent souvent à faire face à l'échelle et à la complexité de ces données. Pour ce faire de nombreuses questions émergent :

- comment mettre en place une infrastructure capable d'ingérer et de stocker ces flux continus de données ?
- quelles sont les techniques d'analyse les plus appropriées pour extraire des informations pertinentes et exploitables ?
- comment transformer ces données brutes en indicateurs clés de performance, en alertes de sécurité ou en prédictions de pannes ?

Forts de cette identification de la problématique, il est essentiel de définir clairement les objectifs que nous nous fixons à travers ce travail de recherche.

1.3. Objectifs du mémoire

Cette section a pour but de préciser les buts que nous souhaitons atteindre à travers cette étude. Nous distinguerons un objectif général, qui encadre l'ensemble de notre démarche, et des objectifs spécifiques, qui détaillent les étapes nécessaires pour atteindre cet objectif principal.

1.3.1. Objectif général

L'objectif général de ce mémoire est de concevoir et de proposer un modèle de pipeline de données optimisé pour l'ingestion et l'analyse des logs système au sein d'un environnement Big Data. Pour atteindre cet objectif global, il est nécessaire de définir des étapes plus précises et mesurables qui guideront notre travail.

1.3.2. Objectifs spécifiques

Afin de concrétiser l'objectif général, ce mémoire s'articule autour de plusieurs objectifs spécifiques qui guideront notre démarche. Ces objectifs spécifiques incluent :

- identifier et à analyser les différentes technologies et architectures Big Data pertinentes pour la mise en place d'un tel pipeline.
- étudier les meilleures pratiques et les techniques d'ingestion, de stockage et de traitement des données de logs à grande échelle.
- explorer les méthodes d'analyse de logs, allant de la simple agrégation aux techniques d'apprentissage automatique, afin d'identifier des patterns, des anomalies ou des tendances significatives.
- Proposer une architecture de pipeline de données concrète, en détaillant les composants, les flux de données et les outils à mettre en œuvre.

En conclusion de cette section, la réalisation de ces objectifs spécifiques nous permettra d'atteindre l'objectif général de ce mémoire et de proposer une solution pertinente pour l'ingestion et l'analyse des logs système dans un environnement Big Data. La pertinence de notre sujet se manifeste à travers les bénéfices qu'il peut apporter à différentes parties prenantes.

1.4. Intérêts du mémoire

L'étude que nous proposons présente un intérêt certain, tant pour les organisations confrontées à la gestion de volumes importants de logs que pour l'enrichissement de nos propres compétences en tant que futur professionnel de la donnée.

1.4.1. Pour l’organisation

Pour les organisations évoluant dans un environnement Big Data, la mise en place d'un pipeline de données efficace pour l'analyse des logs système offre de nombreux avantages. En conclusion, l'adoption d'un tel pipeline représente un investissement stratégique pour les organisations souhaitant tirer pleinement parti de leurs données de logs et améliorer leur efficacité opérationnelle et leur sécurité. Cet intérêt pour les organisations se double d'un intérêt significatif pour l'étudiant que nous sommes.

1.4.2. Pour l’étudiant

Ce projet de mémoire représente une opportunité unique d'approfondir mes connaissances dans le domaine du Big Data et de l'ingénierie des données. Ce sujet de mémoire constitue un véritable tremplin pour mon développement professionnel et nous permettra d'acquérir une expertise significative dans un domaine en pleine expansion.

En définitive, nous avons posé les bases de notre étude en contextualisant l'importance de l'analyse des logs dans le Big Data, en identifiant la problématique centrale, en définissant des objectifs clairs et en soulignant les intérêts de ce travail. Le chapitre suivant s'attachera à explorer le cadre théorique et l'état de l'art relatifs aux technologies Big Data et aux méthodes d'analyse de logs.

Chapitre 2 : Solutions similaires

Ce chapitre explore les solutions existantes et les approches adoptées pour l'ingestion et l'analyse des logs système dans des environnements Big Data. L'objectif est d'identifier les forces et les faiblesses de ces solutions, les critères clés de comparaison et les enseignements à tirer pour la conception du pipeline de données proposé dans ce mémoire. L'écosystème Big Data offre une variété d'outils et de plateformes conçus pour gérer de grands volumes de données, y compris les logs système.

2.1. Critères de comparaison fonctionnels

Pour commencer, cette section définit les critères fonctionnels essentiels pour évaluer les solutions d'ingestion et d'analyse de logs système dans un contexte Big Data. Ces critères se concentrent sur ce que les solutions sont capables de faire en termes de traitement et de manipulation des données de logs. L'évaluation des solutions sur la base de ces critères fonctionnels permettra de déterminer leur adéquation aux besoins spécifiques d'ingestion et d'analyse des logs système dans un environnement Big Data. La section suivante examinera les critères de comparaison non fonctionnels, qui se concentrent sur les aspects de performance, de fiabilité, de coût et de facilité d'utilisation des solutions.

2.2. Critères de comparaison non-fonctionnels

Pour introduire cette section, nous allons définir les critères non fonctionnels qui sont tout aussi importants que les aspects fonctionnels pour évaluer l'efficacité globale et la viabilité des solutions d'ingestion et d'analyse de logs en environnement Big Data. Nous présenterons une étude détaillée de certaines solutions similaires couramment utilisées pour l'ingestion et l'analyse de logs en environnement Big Data.

2.3. Etude détaillée des solutions similaires

Pour commencer, cette section examine en détail plusieurs solutions logicielles et plateformes populaires utilisées pour l'ingestion, le traitement, le stockage et l'analyse des logs système dans des environnements Big Data. Pour chaque solution, nous décrirons son architecture, ses principales fonctionnalités, ses points forts et ses limitations potentielles en relation avec les critères de comparaison définis précédemment.

2.4. Tableaux comparatifs

Afin de faciliter la comparaison, cette section présente des tableaux synthétisant l'évaluation des solutions similaires étudiées précédemment en fonction des critères fonctionnels et non fonctionnels définis. Ces tableaux permettront une visualisation claire des forces et des faiblesses de chaque solution par rapport aux critères établis, facilitant ainsi l'identification des solutions les plus adaptées à différents contextes et exigences.

2.4.1. Tableau comparatif pour les critères fonctionnels

Pour illustrer les différences fonctionnelles, ce tableau compare les solutions étudiées en se basant sur leur capacité à supporter différentes sources et formats de logs, à transformer et enrichir les données, à les stocker efficacement, à offrir des fonctionnalités d'analyse et de requête, de monitoring et d'alerte, ainsi que leur intégration avec d'autres outils.

2.4.2. Tableau comparatif pour les critères non-fonctionnels

Pour compléter l'analyse, ce tableau compare les solutions étudiées en se basant sur des aspects tels que la performance, la scalabilité, la fiabilité, la sécurité, le coût, la facilité d'utilisation et la disponibilité du support et de la communauté.

2.5. Conclusion majeure tirée des deux tableaux comparatifs

En guise d'introduction, cette section synthétise les principales conclusions qui se dégagent de la comparaison des solutions d'ingestion et d'analyse de logs Big Data en fonction des critères fonctionnels et non fonctionnels. Pour conclure ce chapitre, l'examen des solutions similaires a permis d'identifier les critères clés de comparaison et de comprendre les forces et les faiblesses des approches existantes.

Chapitre 3 : Analyse de l’existant et conception de la solution proposée

Ce chapitre constitue le cœur de notre démarche méthodologique. Il s'articule autour d'une analyse approfondie des use cases métiers existants en matière de gestion et d'analyse des logs système, afin de mettre en lumière les forces et les faiblesses des approches actuelles. Sur cette base, nous aurons les use cases métiers ciblés par notre future solution, avant de formaliser sa conception à travers des diagrammes UML et des maquettes d'interfaces utilisateur (IHM). Enfin, nous présenterons l'architecture fonctionnelle de la solution proposée et les outils technologiques que nous envisageons d'utiliser pour sa mise en œuvre.

3.1. Use case métiers existants

Afin de bien comprendre les besoins et les défis liés à l'analyse des logs système dans un contexte Big Data, il est essentiel d'examiner les use cases métiers actuellement rencontrés par les organisations. En somme, cette analyse, il ressortira une vision claire des pratiques actuelles en matière d'exploitation des logs système, mettant en évidence les lacunes et les besoins auxquels notre future solution devra répondre.

3.2. Use case métier de la future solution

Cette section est dédiée à la présentation des scénarios d'utilisation concrets que notre future solution de pipeline de données pour l'ingestion et l'analyse des logs système permettra de réaliser dans un environnement Big Data. En conclusion, la définition claire de ces use cases métiers futurs permettra de guider la conception de notre solution et de s'assurer qu'elle répondra efficacement aux besoins identifiés.

3.3. Diagrammes UML

Les diagrammes UML (Unified Modeling Language) sont des outils de modélisation essentiels pour représenter la structure et le comportement d'un système logiciel. Dans cette section, nous allons nous concentrer sur les diagrammes d'activités pour illustrer les flux de travail et les processus au sein de notre future solution.

3.3.1. Diagramme des activités

Les diagrammes d'activités permettent de décrire le déroulement des opérations et les séquences d'actions au sein d'un processus. Ils sont particulièrement utiles pour visualiser les étapes de notre pipeline de données, depuis l'ingestion des logs jusqu'à leur analyse et la production de

résultats. En termes de conclusion les diagrammes d'activités fourniront une représentation visuelle et compréhensible des processus fondamentaux de notre solution, facilitant ainsi sa conception et sa communication.

3.3.2. Diagramme de classe

Les diagrammes de classe UML permettent de représenter la structure statique d'un système en décrivant ses classes, leurs attributs et leurs relations. Ils nous aideront à visualiser les principaux composants de notre pipeline de données et leurs interactions. En somme, les diagrammes de classe offriront une vue d'ensemble de l'architecture interne de notre pipeline de données et des liens entre ses différents composants logiciels.

3.4. Les dessins des IHM métiers

L'interface homme-machine (IHM) est un élément essentiel pour l'interaction des utilisateurs avec notre solution. Des dessins ou maquettes des IHM métiers permettront de visualiser l'expérience utilisateur et de s'assurer qu'elle répond aux besoins des analystes et des administrateurs. Enfin ces dessins d'IHM métiers donneront une idée concrète de la manière dont les utilisateurs interagiront avec notre pipeline de données et permettront de valider l'adéquation de l'interface à leurs besoins.

3.5. Architecture fonctionnelle de la solution

L'architecture fonctionnelle décrit les principales fonctions du système et la manière dont elles interagissent entre elles, en se concentrant sur ce que le système fait plutôt que sur la manière dont il le fait. En définitive, la présentation de l'architecture fonctionnelle permettra d'avoir une vision globale du fonctionnement de notre solution et de la manière dont les différentes étapes du traitement des logs s'articulent.

3.6. Outils utilisés

Le choix des outils et des technologies est déterminant pour la mise en œuvre et la performance de notre pipeline de données Big Data. Pour conclure, la justification du choix de ces outils permettra de démontrer la faisabilité technique et l'adéquation de notre approche pour la construction d'un pipeline de données performant et adapté à l'analyse des logs système dans un environnement Big Data. Ces éléments constituent une base solide pour la phase de mise en œuvre et d'évaluation qui sera abordée dans le chapitre suivant.

Chapitre 4 : Réalisation de la solution proposée

Ce chapitre décrit la mise en œuvre concrète de la solution de pipeline de données que nous avons conçue au chapitre précédent. Nous détaillerons les étapes de développement du backend et du frontend, le déploiement de l'application, l'architecture technique qui sous-tend la solution, et les outils utilisés tout au long du processus de réalisation.

4.1. Réalisation du Backend

Le backend constitue le cœur de notre application, assurant la logique métier, la gestion des données et les interactions avec les différentes composantes du système. Ainsi après avoir exploré cette section nous détaillerons la manière dont nous avons conçu et développé les interfaces utilisateur de notre application, en mettant l'accent sur l'expérience utilisateur et la visualisation efficace des données de logs.

4.2. Réalisation Frontend (Interfaces Web et mobiles)

Le frontend assure l'interface utilisateur de notre application, permettant aux utilisateurs d'interagir avec le système, de visualiser les données de logs et d'accéder aux fonctionnalités d'analyse. En définitive, nous détaillerons la manière dont nous avons conçu et développé les interfaces utilisateur de notre application, en mettant l'accent sur l'expérience utilisateur et la visualisation efficace des données de logs.

4.3. Déploiement de l'application (Conteneurs Dockers, etc.)

Le déploiement de l'application est une étape cruciale qui consiste à mettre en production notre solution, en la rendant accessible aux utilisateurs dans un environnement réel. L'approche adoptée dans cette section nous fournira une description détaillée de la manière dont nous avons déployé notre application, en mettant en évidence les avantages de l'approche choisie en termes de portabilité, de scalabilité et de facilité de gestion.

4.4. Architecture technique de la future solution

L'architecture technique décrit l'infrastructure matérielle et logicielle qui sous-tend notre solution, en précisant les composants, leurs interactions et les technologies utilisées. En résumé, cette section fournira une description claire et concise de l'architecture technique de

notre solution, en mettant en évidence les choix technologiques clés et leur impact sur les performances et les caractéristiques de l'application.

4.5. Outils utilisés

La réalisation de notre solution a nécessité l'utilisation d'un ensemble d'outils et de technologies spécifiques. En conclusion de ce chapitre, nous avons décrit en détail le processus de réalisation de notre solution de pipeline de données pour l'ingestion et l'analyse des logs système. Nous avons couvert le développement du backend et du frontend, le déploiement de l'application, l'architecture technique sous-jacente et les outils utilisés. Le chapitre suivant sera consacré à l'évaluation de la solution proposée, en présentant les résultats obtenus et en analysant leur pertinence par rapport aux objectifs fixés.

Chapitre 5 : Conclusions et perspectives

Ce chapitre finalise le sujet portant sur la mise en place d'un pipeline de données dédié à l'ingestion et à l'analyse des logs système dans un environnement Big Data. Il présente une synthèse des travaux réalisés, les apports du projet ainsi que les pistes d'amélioration envisageables.

5.1. Conclusions

Ce mémoire avait pour objectif de concevoir un pipeline de données capable de collecter, traiter, stocker et analyser des logs système en environnement Big Data.
Le pipeline repose sur quatre étapes essentielles :

- ingestion (via Fluentd, Filebeat, Logstash),
- stockage distribué (Kafka, HDFS),
- visualisation (Kibana, outils BI).

Il permet d'analyser les événements système, détecter des anomalies et faciliter la prise de décision rapide, tout en assurant performance, résilience et scalabilité. Les résultats obtenus valident la faisabilité et l'efficacité de la solution mise en place, tout en posant une base solide pour des évolutions futures.

5.2. Perspectives

Des améliorations sont envisageables pour faire évoluer le pipeline, notamment :

- optimiser la latence pour un traitement en quasi temps réel,
- renforcer la sécurité avec chiffrement et authentification,
- automatiser les déploiements avec des outils DevOps (Terraform, Ansible).

En poursuivant ces axes, la solution pourrait devenir plus intelligente, agile et adaptée aux enjeux futurs du Big Data.